

Valerija Teovanović RA 187/2023

SAUSUA projekat

Predikcija završne ocene učenika

1. UVOD

1.1 Cilj projekta

Cilj projekta je razvoj modela za predviđanje završne ocene (G3) na osnovu demografskih, socijalnih i akademskih atributa. Skup podataka je prikupljen u okviru istraživanja o školskim uspesima učenika srednjih škola u Portugalu, kombinovani su rezultati školskih izveštaja i anketa, a obuhvataju rezultate iz matematike i Portugalskog jezika.

Posebna pažnja posvećena je analizi uticaja ocena iz prvog i drugog polugodišta (G1 i G2) na tačnost predikcije. Pored toga, analizirani su i ostali atributi koji takođe imaju visok stepen korelacije sa završnom ocenom, a dobijaju na značaju kada ocene sa polugodišta nisu dostupne.

1.2 Opis skupa podataka

Korišćeni skup podataka sadrži sledeće karakteristike:

- Broj instanci: 649 učenika
- Broj atributa: 33 originalna atributa (42 nakon preprocesiranja)
- Ciljna promenljiva: G3 - završna ocena na skali 0-19
- Tip problema: Regresija

Atributi obuhvataju demografske informacije (pol, starost, tip adrese), porodične faktore (obrazovanje roditelja, veličina porodice), akademske faktore (broj prethodnih neuspeha, vreme učenja, školska podrška) i socijalne faktore (konzumacija alkohola tokom vikenda i radnih dana, slobodne aktivnosti, izlasci)


2. Preprocesiranje podataka

2.1 Provera kvaliteta podataka

Pre treniranja izvršena je detaljna obrada podataka:

- Nedostajuće vrednosti: Skup podataka ne sadrži ni jednu nedostajuću vrednost, svi atributi su potpuno popunjeni.
- Duplikati: Nije pronađen ni jedan duplirani red.
- Anomalije u godinama: Sve vrednosti su u opsegu od 15-22, što odgovara učeniku srednje škole
- Anomalije u ocenama: Sve ocene G1, G2 i G3 nalaze se u validnom opsegu 0-19

Jedina uočena anomalija tiče se atributa absences, tu su detektovani učenici sa ekstremnim brojem izostanaka (više od 17), što je prikazano na sledećem grafikonu:



Slika 1: Detekcija ekstremnih vrednosti u broju izostanaka (boxplot)

Analiza grafikona ukazuje na to da se najveći broj učenika nalazi unutar obojene kutije, odnosno u rasponu od 0 do 6 izostanaka. Činjenica da polovina učenika ima 2 ili manje izostanaka potvrđuje visok nivo redovnosti u pohađanju nastave. Kao kriterijum za identifikaciju ekstremnih vrednosti korišćena je granica od tri standardne devijacije iznad proseka (prikazana isprekidanom linijom). Učenici čiji broj izostanaka prelazi ovu granicu ($n=11$, označeni na grafikonu) zadržani su u datasetu, jer predstavljaju realne, a ne greškom unete vrednosti — npr. učenike sa izrazito niskim pohađanjem nastave koji i dalje imaju validne ocene.

2.2 Enkodiranje atributa


Svi atributi transformisani su u numerički format pogodan za algoritme mašinskog učenja:

- **Binarno enkodiranje** – Primenjeno je na 13 atributa sa dve kategorije (school, sex, address, famsize, Pstatus, schoolsup, famsup, paid, activities, nursery, higher, internet, romantic). Svaki od atributa ima dve vrednosti i one su promenjene u 0 ili 1. Na ovaj način je omogućeno da algoritmi mašinskog učenja pravilno interpretiraju ove kvalitativne podatke bez veštačkog povećanja dimenzionalnosti skupa podataka.
- **One-Hot enkodiranje** – Primenjeno na 4 atributa sa više od dve kategorije (Mjob, Fjob, reason, guardian). Ove kategoričke promenljive su transformisane u binarne indikatore, što je rezultovalo dodavanjem 13 novih kolona u skup podataka. Na ovaj način je sprečeno da model pogrešno interpretira tekstualne kategorije kao rangirane numeričke vrednosti, čime je očuvana objektivnost modeliranja.

Nakon enkodiranja dataset je porastao sa 33 na 42 atributa.

2.3 Analiza korelacije

Izvršena je analiza korelacije između svih numeričkih atributa, posebna pažnja posvećena je korelaciji između atributa G1, G2 i ciljane promenljive G3.



Slika 2: Matrica korelacije ključnih atributa sa završnom ocenom G3

Analiza korelacije otkrila je sledeće ključne nalaze:

- **Dominacija prethodnih akademskih rezultata** – ocene iz prvog i drugog polugodišta predstavljaju daleko najjači prediktor završne ocene. G2 sa G3 = 0.92 i G1 sa G3 = 0.83 što nam govori da je akademski kontinuitet ključni deo uspeha.
- **Negativni indikator uspeha** - Broj prethodnih neuspeha u školovanju ima značajnu negativnu korelaciju sa završnom ocenom (G3=-0.39), što ga čini najjačim pojedinačnim indikatorom potencijalnog akademskog rizika. Takođe, uočena je blaga negativna korelacija sa konzumacijom alkohola radnim danima (Dalc= -0.20) i vikendom (Walc = -0.18).
- **Pozitivni socijalni i akademski faktori:** Vreme posvećeno učenju na nedeljnom nivou (studytime) očekivano pokazuje pozitivan uticaj na uspeh

(0.25). Pored toga, nivo obrazovanja majke (Medu = 0.24) i oca (Fedu = 0.21) blago pozitivno korelira sa ocenom učenika, ukazujući na uticaj porodičnog okruženja.


Međutim analizom je primećen visok stepen multikolinearnosti među pojedinim atributima (npr. Medu sa Fedu = 0.65, kao i Dalc sa Walc = 0.62). Najvažniji uvid koji smo stekli iz ove analize jeste da visoka korelacija između G1 i G2 može potpuno da maskira uticaj ostalih sociodemografskih atributa. Linearna regresija je osetljiva na multikolinearnost (nestabilni koeficijenti), dok stabla odlučivanja i Random Forest praktično nisu osetljivi na nju (biraju jedan od koreliranih atributa za podelu, ignorišu drugi)

Na osnovu svega prethodno navedenog doneta je odluka da se razviju dva modela

- **Sa ocenama G1 i G2**
- **Bez ocena G1 i G2** - oslanjajući se isključivo na profile učenika i ostale faktore.

Ova podela omogućava da se proceni koliko je akademski uspeh učenika predvidiv isključivo iz demografskog i socijalnog profila, nezavisno od prethodnih ocena — rezultati ovog poređenja prikazani su u narednom poglavlju.

2.4 Odnos atributa i G3



Slika: Odnos pojedinačnih atributa i završne ocene

Vizualizacija pojedinačnih atributa naspram G3 potvrđuje i ilustruje nalaze korelacione analize konkretnim brojevima. Najizraženiji efekti uočeni su kod failures i higher: učenici bez prethodnih padova imaju prosečnu ocenu 12.51, naspram 8.07–8.81 kod onih sa bar jednim padom — razlika od preko 4 poena. Slično, učenici koji žele nastavak školovanja imaju prosečnu ocenu 12.28, naspram 8.80 kod onih koji ne žele — razlika od 3.5 poena. Atributi Medu i studytime pokazuju

blaži, ali dosledan rastući trend sa prosečnom ocenom, dok goout pokazuje nemonoton, blago zvonast obrazac — najviša prosečna ocena (12.67) zabeležena je kod učenika sa umerenom učestalošću izlazaka, ne kod onih koji izlaze najmanje ili najviše.

3. Treniranje i evaluacija modela

3.1 Metodologija

Nakon uklanjanja administrativnih anomalija (učenici sa $G3=0$ i $absences=0$, ukupno 634 preostala učenika), podeljeni su u tri skupa 70/15/15:

- Trening skup (70% - 443 učenika): korišćen za treniranje modela.
- Validacioni skup (15% - 95 učenika): korišćen za odabir optimalnih hiperparametara.
- Test skup (15% - 96 učenika): korišćen isključivo za finalnu evaluaciju performansi, nakon što su model i hiperparametri već izabrani.

Za svaki skup atributa (sa i bez $G1/G2$) trenirani su sledeći modeli:

- Linearna regresija – bazni model, pretpostavlja linearnu vezu između atributa i ocene
- Stablo odlučivanja - nelinearni model koji predikciju formira kroz niz jedinstvenih pitanja nad atributima.
- Slučajna šuma - ansambl od 100 stabala odlučivanja, stabilniji i tačniji od pojedinačnog stabla.

Za svaki od ova tri modela treniran je default model i za Stablo i Slučajnu šumu dodatno i tuned model. Optimalni hiperparametri birani su putem ručno implementirane Grid Search pretrage: sistematski je isprobana svaka kombinacija unapred definisanih vrednosti hiperparametara (npr. `max_depth`, `min_samples_split`, `min_samples_leaf` za stablo; `n_estimators`, `max_depth`, `min_samples_split` za šumu), a kao kriterijum izbora korišćena je MAE vrednost na validacionom skupu. Da bi poređenje između default i tuned modela bilo fer, finalni model — bez obzira da li je default ili tuned — uvek se trenira isključivo na trening skupu (443 učenika); validacioni skup koristi se samo za izbor hiperparametara, nikad za finalno treniranje, čime je obezbeđeno da svi kandidati vide identičnu količinu podataka.

Kao dodatna provera pouzdanosti rezultata, sprovedena je 5-fold cross-validation na trening skupu za sva tri default modela. Ova provera ima isključivo dijagnostičku ulogu — pokazuje koliko je dobijeni rezultat osetljiv na slučajnost konkretne podele podataka — i ne utiče na izbor modela ili hiperparametara, koji se zasniva na rezultatima validacionog i test skupa.

3.2 Metrike evaluacije

Za evaluaciju performansi korišćene su tri komplementarne metrike:

- MAE (Mean Absolute Error) - prosečna apsolutna greška u ocenama. Npr. $MAE=0.73$ znači da model u proseku greši ± 0.73 ocene. Intuitivna je i lako tumačiva u kontekst konkretnog problema.
- RMSE (Root Mean Squared Error) - kvadratni koren srednje kvadratne greške. Zbog kvadriranja, veća pojedinačna odstupanja imaju nesrazmerno veći uticaj na vrednost RMSE nego na MAE, pa je RMSE uvek veći ili jednak MAE (jednakost važi samo ako su sve greške po apsolutnoj vrednosti identične, što se na realnim podacima praktično ne dešava).
- R^2 (koeficijent determinacije) - udeo varijanse u $G3$ koji model objašnjava. $R^2=0.90$ znači da model objašnjava 90% varijabilnosti u završnim ocenama. Vrednost blizu 1.0 je idealna; vrednost 0 znači da model nije bolji od proste prosečne predikcije; negativna vrednost znači da je model lošiji od te proste prosečne predikcije — takav slučaj je i uočen u ovom projektu kod modela treniranog na selektovanom podskupu atributa bez $G1/G2$ (u nastavku će biti detaljnije objašnjeno) što ukazuje na nestabilnost modela pri ograničenoj prediktivnoj moći raspoloživih atributa.

MAE je izabran kao primarni kriterijum za izbor modela jer je direktno tumačiv u jedinicama ocene (broj poena greške), tretira sve greške proporcionalno (za razliku od RMSE koji nesrazmerno kažnjava veća odstupanja), i u praksi vodi ka istom rangiranju modela kao i R^2 , ali je intuitivniji za komunikaciju krajnjem korisniku aplikacije

3.3 Rezultati – sa $G1$ i $G2$

Model	MAE	RMSE	R^2
Linearna regresija	0.727	0.921	0.899
Stablo odlučivanja	0.838	1.067	0.864
Slučajna šuma	0.781	0.972	0.888
Stablo odlučivanja (tuned)	0.751	0.931	0.897
Slučajna šuma (tuned)	0.767	0.956	0.891


Tabela 1: Metrike modela – sa $G1$ i $G2$

U Tabeli 1 prikazani su rezultati evaluacije pet različitih konfiguracija modela na test skupu kada su dostupne parcijalne ocene $G1$ i $G2$. Kao primarni kriterijum selekcije korišćena je MAE metrika.

Najbolje performanse ostvarila je Linearna regresija sa najnižom srednjom apsolutnom greškom od 0.727 i najvišim koeficijentom determinacije R^2 od 0.899 (model objašnjava 89.9% varijabiliteta ciljne promenljive). Ovaj rezultat ukazuje na to da je odnos između tekućih ocena ($G1$, $G2$) i finalnog uspeha ($G3$) dominantno

linearan, zbog čega kompleksniji nelinearni modeli poput Slučajne šume (MAE = 0.781, odnosno 0.767 nakon tuninga) nisu doneli značajan napredak. Dodatna analiza kroz 5-fold cross-validation pokazuje da je ova prednost Linearne regresije statistički skromna: razlika u CV-MAE u odnosu na Slučajnu šumu (0.675 naspram 0.692) manja je od standardne devijacije te šume kroz foldove (std=0.078), što ukazuje da rangiranje modela nije izrazito robusno na slučajnost konkretne podele podataka.

Takođe se uočava uspešnost faze podešavanja hiperparametara (tuning): kod Stabla odlučivanja, optimizacijom parametara na validacionom skupu (gde je izabrana kombinacija sa najnižim MAE), MAE greška na nezavisnom test skupu je usledično smanjena sa 0.838 na 0.751, čime je dokazana opravdanost uvođenja validacionog skupa u pipeline. Pобољшanje je posledica regularizacije, a ne povećanja kompleksnosti — optimalna dubina stabla (max_depth=5) ostala je nepromenjena, dok su min_samples_split i min_samples_leaf povećani sa (2, 1) na (5, 2), čime je stablu otežano da formira podele zasnovane na malom broju uzoraka. Kod Slučajne šume tuning je doneo svega marginalno poboljšanje, što potvrđuje da je ansambl pristup već sa podrazumevanim parametrima blizu svog optimuma na ovom skupu podataka.



Slika 3: Prosečna greška po opsegu ocena

Analiza greške po opsegu ocena (Slika 3) otkriva da svi modeli ostvaruju značajno veću grešku za niske ocene (≤ 9) u odnosu na srednje i visoke, što je očekivano s obzirom na to da ove vrednosti čine manjinu uzoraka u datasetu. Stablo odlučivanja pokazuje najizraženiji ovaj efekat (MAE=1.36 za niske ocene), što je u skladu sa njegovom poznatom osetljivošću na regione prostora atributa sa malim brojem trening primera.

3.4 Rezultati – Bez G1 i G2

Model	MAE	RMSE	R^2
Linearna regresija	2.207	2.675	0.148

Stablo odlučivanja	2.073	2.617	0.185
Slučajna šuma	2.127	2.635	0.173
Stablo odlučivanja (tuned)	2.073	2.617	0.185
Slučajna šuma (tuned)	2.044	2.552	0.225


Tabela 2: Metrike modela – bez G1 i G2

U Tabeli 2 prikazani su rezultati evaluacije u scenariju gde su iz skupa podataka potpuno isključene tekuće ocene G1 i G2, čime je fokus modela prebačen isključivo na socio-demografske faktore i navike učenika.

Uklanjanje parcijalnih ocena dovelo je do očekivanog i značajnog pada performansi kod svih modela, što implicira da socio-demografski atributi nose znatno manje prediktivne informacije o završnoj oceni. Linearna regresija je ostvarila najslabiji rezultat ($MAE = 2.207$, $R^2 = 0.148$), što ukazuje da je veza ovih atributa sa G3 izraženije nelinearna ili slabija nego kod G1/G2, pa pretpostavka linearnosti postaje ograničavajuća.

Najbolje performanse demonstrirao je optimizovani model Slučajne šume (tuned), sa $MAE=2.044$ i $R^2 = 0.225$. Nizak R^2 ukazuje na ograničenu prediktivnu informaciju, posebno o ekstremnim vrednostima — model predviđa ocene u rasponu [7.61, 15.75], dok se stvarne ocene kreću od 1 do 19, što pokazuje tipičnu tendenciju modela sa slabim signalom da predikcije "povlači" ka centralnim vrednostima distribucije.


Dodatno, 5-struka unakrsna validacija pokazuje da je Slučajna šuma ovde osetljivija na podelu podataka nego na skupu sa G1/G2 (std=0.127, najviša izmerena vrednost u istraživanju), verovatno zbog slabijeg signala u socio-demografskim atributima. Tuning je kod Slučajne šume doneo merljivo poboljšanje (MAE sa 2.127 na 2.044), dok kod Stabla odlučivanja nije — pronađena je identična kombinacija hiperparametara kao podrazumevana.



Slika 4: Prosečna greška po opsegu ocena

Analiza greške po opsegu ocena (Slika 4) potvrđuje i kvantifikuje tendenciju modela da predikcije povlači ka centralnim vrednostima: greška je za sva tri modela 2 do 2.5 puta veća na rubovima distribucije (Niske ≤ 9 : MAE 2.8–3.2; Visoke ≥ 14 : MAE 2.4–2.6) nego u centralnom opsegu (Srednje 10–13: MAE 1.3–1.7). Ovaj obrazac je znatno izraženiji nego u scenariju sa G1/G2, gde je razlika između opsega bila znatno blaža — što potvrđuje da je dominantan uzrok ovog efekta upravo odsustvo G1/G2 signala, a ne sama priroda problema. Stablo odlučivanja pokazuje ekstremnu varijaciju između opsega — najveću grešku na niskim ocenama (MAE=3.24) i najmanju na srednjim (MAE=1.28) — što odražava njegovu tendenciju da se prilagodi gustom, dobro zastupljenom centralnom regionu distribucije, dok slabije generalizuje na retko zastupljene, ekstremne vrednosti ocena.

3.5 Poređenje pristupa




Slika 5: Poređenje metrika – Sa G1/G2 vs Bez G1/G2

Slika 5 prikazuje uporedne rezultate sve tri metrike za svih pet konfiguracija modela, na oba skupa atributa. Razlika u performansama između scenarija sa i bez G1/G2 dosledna je kroz sve modele — R^2 opada sa raspona 0.86–0.90 na 0.15–0.23 nezavisno od izabranog algoritma, što potvrđuje da je dominacija G1/G2 strukturalno svojstvo problema, a ne artefakt određenog modela. Primetno je i da tuning kod Stabla odlučivanja na skupu bez G1/G2 nije promenio rezultat (MAE ostaje 2.07) — pretragom hiperparametara pronađena je kombinacija identična podrazumevanim vrednostima, što ukazuje da je default konfiguracija već bila blizu optimuma za ovaj specifičan skup atributa.

4. Analiza važnosti atributa

4.1 Važnost atributa – bez G1 i G2

Analizirana je važnost atributa za tuned modele u scenariju bez G1 i G2, kako bi se identifikovali ključni socijalni i demografski prediktori akademskog uspeha.



Slika 6: Važnost atributa za tuned modele

Analiza važnosti atributa (Slika 6), prikazana isključivo za tuned modele, otkriva različite obrasce raspodele važnosti kod Slučajne šume i Stabla odlučivanja. Kod Slučajne šume važnost je relativno ravnomerno raspoređena (0.02–0.18), bez izrazito dominantnog atributa, što je posledica nasumičnog uzorkovanja atributa pri svakoj podeli — karakteristika koja sprečava da jedan atribut sistematski dominira ansamblom. Kod pojedinačnog Stabla odlučivanja, naprotiv, important je znatno koncentrisanija: failures (0.39) i higher (0.18) zajedno čine većinu ukupne važnosti, dok Mjob_teacher praktično ne doprinosi modelu (≈ 0). Ovo poslednje je zanimljiv nalaz s obzirom na to da je Mjob_teacher uključen u skup atributa upravo na osnovu formalne selekcije (SelectKBest i RFE, poglavlje X) — razilaženje sa Feature Importance rezultatom ukazuje da različite metode selekcije atributa mogu doći do različitih zaključaka o korisnosti istog atributa, zavisno od toga da li detektuju linearnu/statističku povezanost (SelectKBest, RFE) ili doprinos konkretnim podelama u stablu (Feature Importance).


4.2 Metode za odabir najznačajnijih atributa

Primenjene su tri različite metode za odabir najznačajnijih atributa, namerno biranje raznovrsnih pristupa kako bi se izbeglo oslanjanje na jedan kriterijum:

- Feature Importance (Random Forest) — meri koliko svaki atribut doprinosi smanjenju greške pri podelama unutar stabala; hvata i nelinearne odnose.
- SelectKBest (F-statistika) — statistički test koji meri snagu linearne veze između svakog atributa pojedinačno i ciljne promenljive.
- RFE (Recursive Feature Elimination) — iterativno izbacuje najslabiji atribut na osnovu Linearne regresije kao osnovnog modela, i ponovo trenira preostale.

Budući da SelectKBest i RFE suštinski procenjuju linearnu povezanost atributa sa ciljnom promenljivom, dok Feature Importance hvata i nelinearne efekte kroz strukturu stabala, finalni presek metoda (atributi izabrani od strane bar dve od tri) favorizuje attribute koji pokazuju doslednu važnost nezavisno od pretpostavke o linearnosti.

4.2.1 Sa G1 i G2




Slika 7: Odabir atributa – sa G1 i G2

Analiza važnosti atributa na skupu sa G1 i G2 (Slika 7) potvrđuje nalaze iz prethodnih poglavlja. Kod Feature Importance (Random Forest), G2 nosi preko 85% ukupne važnosti, dok je doprinos svih ostalih atributa, uključujući G1, gotovo zanemarljiv. Isti obrazac potvrđuje i SelectKBest — F-statistika za G2 i G1 višestruko nadmašuje vrednosti svih preostalih atributa, gde je sledeći najjači (failures) tek na trećem mestu sa znatno nižom vrednošću.

RFE, međutim, daje rezultat koji odstupa od druge dve metode — rangira age kao najvažniji atribut, dok G1 i G2 svrstava među niže rangirane. Ovo se objašnjava osetljivošću RFE-a (sa Linearnom regresijom kao osnovnim estimatorom) na multikolinearnost: kada su G1 i G2 međusobno jako korelirani, a pritom oba korelirana sa G3, koeficijenti linearnog modela mogu postati nestabilni, što narušava pouzdanost rangiranja zasnovanog isključivo na njihovoj veličini. Iz ovog razloga je presek od najmanje dve metode korišćen kao robusniji kriterijum od

oslanjanja na bilo koju metodu pojedinačno — RFE rezultat na ovom skupu je tretiran kao manje pouzdan, usled poznatog ograničenja metode u prisustvu jako koreliranih atributa.

4.2.2 Bez G1 i G2



Slika 8: Odabir atributa – bez G1 i G2

Analiza važnosti atributa na skupu bez G1 i G2 (Slika 8) pokazuje znatno ujednačeniju raspodelu u odnosu na skup sa parcijalnim ocenama. Feature Importance i SelectKBest se ovde dobro slažu — failures, higher, studytime i school se nalaze među najvažnijim atributima u oba panela, što odgovara i sastavu finalne FEAT_BEZ liste dobijene presekom metoda.

RFE i na ovom skupu odstupa od preostale dve metode, rangirajući attribute poput paid, guardian_other i reason_home kao najvažnije — nijedan od njih se ne pojavljuje među vodećim atributima u Feature Importance ili SelectKBest panelima. Ovo je isti fenomen primećen i na skupu sa G1/G2 : RFE sa Linearnom regresijom kao osnovnim estimatorom je osetljiv na multikolinearnost među atributima, što čini njegovo rangiranje manje pouzdanim u poređenju sa preostale dve metode. Iako je ovde odstupanje manje upadljivo nego u prisustvu G1/G2 (gde je multikolinearnost najizraženija), isti princip i dalje opravdava korišćenje preseka više metoda — failures, higher i studytime, koje RFE svrstava niže, ipak ulaze u finalni skup zahvaljujući doslednoj podršci druge dve metode.

5. Zaključak

5.1 Diskusija rezultata

Rezultati projekta jasno pokazuju da postoje dva suštinski različita scenarija predikcije završne ocene učenika:

Scenario 1 — Sa ocenama G1 i G2: Model postiže visoku tačnost (najbolji rezultat: Linearna regresija, $R^2=0.899$, $MAE=0.727$). Analiza važnosti atributa pokazala je da G1 i G2 same po sebi nose dominantnu prediktivnu informaciju — uz njihovo prisustvo, doprinos preostalih socio-demografskih atributa postaje gotovo zanemarljiv (poglavlje 4). Ovo je praktično upotrebljiv model koji predviđa završnu ocenu sa prosečnom greškom manjom od jedne ocene.

Scenario 2 — Bez ocena G1 i G2: Model postiže znatno nižu tačnost (najbolji rezultat: Slučajna šuma, tuned, $R^2=0.225$, $MAE=2.044$). Ključni prediktori, prema formalnoj selekciji atributa, su failures, higher, absences i studytime. Model može u ograničenoj meri ukazati na učenike sa povišenim rizikom od neuspeha, ali nije dovoljno precizan za tačnu predikciju konkretne ocene.

5.2 Ograničenja modela

- Model bez G1/G2 objašnjava svega 22.5% varijanse završne ocene — socio-demografski i bihevioralni faktori, sami po sebi, nisu dovoljni za preciznu predikciju, posebno na ekstremnim vrednostima ocene (poglavlje 3).
- Dataset potiče iz dve portugalske škole, što ograničava generalizabilnost modela na druge obrazovne sisteme i kulturne kontekste.
- Ocene su na skali 0–20, specifičnoj za portugalski sistem, što ograničava direktnu primenljivost modela na sisteme sa drugačijom skalom ocenjivanja.
- Model ne uzima u obzir individualne faktore poput motivacije, zdravstvenog stanja ili vanškolskih aktivnosti, koji nisu bili deo raspoloživog dataseta.
- Pri tumačenju važnosti atributa kao što su school i Mjob_teacher treba imati u vidu da je reč o korelaciji, ne uzročnosti — ovi atributi verovatno deluju kao proxy za šire socio-ekonomske faktore, ne kao direktan uzrok uspeha (poglavlje 2.3).

5.3 Praktična upotrebljivost

Model sa G1 i G2 je praktično upotrebljiv za predviđanje završne ocene sredinom školske godine, kada su dostupne ocene iz prvog i drugog perioda. Može poslužiti nastavnicima i školskim psiholozima za rano identifikovanje učenika kojima je potrebna dodatna podrška.

Model bez G1 i G2 može se koristiti na početku školske godine za grubu identifikaciju rizičnih učenika na osnovu dostupnih demografskih i socijalnih

informacija, ali uz svest o znatno ograničenoj preciznosti predikcije — model je pouzdaniji kao indikator relativnog rizika nego kao precizan predviktore konkretne ocene.

5.4 Rezime ključnih nalaza

- Ocene G1 i G2 su daleko najvažniji prediktori završne ocene G3 (korelacija $G2-G3 = 0.92$, $G1-G3 = 0.83$), i njihovo prisustvo maskira doprinos ostalih atributa.
- Bez G1/G2, broj prethodnih neuspeha (failures) postaje najvažniji pojedinačni prediktor (korelacija sa G3 = -0.39).
- Tuning hiperparametara donosi različito poboljšanje zavisno od modela i scenarija — najizraženije kod Stabla odlučivanja na skupu sa G1/G2 (MAE sa 0.838 na 0.751), dok je kod Slučajne šume poboljšanje manje, što je očekivano svojstvo ansambl metoda koje su već sa podrazumevanim parametrima relativno stabilne.
- Formalna selekcija atributa (preseka tri metode) pokazala je da skup od 9 pažljivo izabranih atributa zadržava razuman deo prediktivne informacije u odnosu na pun skup od 39 atributa na scenariju bez G1/G2, uz dodatnu prednost veće interpretabilnosti modela.
- Razvijena Streamlit aplikacija omogućava praktičnu upotrebu oba modela kroz intuitivan korisnički interfejs, sa automatskim odabirom najboljeg modela po MAE kriterijumu za svaki scenario.